

Ciência de Dados: Análise de Dados Aplicada

Prof. Dr. Eduardo Pena

Projeto Final

Objetivo Geral

Nesta atividade, você será um(a) cientista de dados e deverá conduzir uma análise completa de dados, desde a definição do problema até a comunicação dos resultados. O objetivo é demonstrar competências em todas as etapas do processo analítico: integração de dados, análise exploratória, modelagem preditiva e comunicação dos resultados.

Tecnologias Obrigatórias:

- **SQL:** PostgreSQL ou DuckDB para consultas
- **Python/R:** Pandas, scikit-learn, matplotlib/seaborn/ggplot2
- **Versionamento:** Git com commits bem documentados
- **Outros:** Demais bibliotecas Python ou outras ferramentas que julgar necessárias

Grupos: Até três alunos.

1 Escolha do Dataset e Definição do Problema

Nesta etapa, você deve selecionar um conjunto de dados relevante e formular um problema analítico bem estruturado que será investigado ao longo do projeto. **O dataset principal deve obrigatoriamente ser proveniente de uma das três categorias abaixo:**

Tabela 1: Fontes de dados permitidas para o dataset principal

Categoria	Fontes
Brasil	Dados.gov.br
Internacional	NYC Open Data, Data.gov, EU Open Data
Datasets de papers	Veja as instruções abaixo

1.1 Datasets de artigos científicos

Uma das categorias permitidas para o projeto é o uso de datasets associados a artigos científicos publicados em venues de alta qualidade. Nessa modalidade, o grupo deve selecionar um trabalho recente, compreender o problema estudado e desenvolver uma análise própria a partir dos dados

Tabela 2: Venues recomendadas (podem usar papers de outros anos)

Conferência	Track/Seção
KDD	Datasets and Benchmarks Track
CIKM	Accepted Papers
ECML-PKDD	Applied Data Science Track
AAAI	Applications Track

utilizados no artigo. Essa abordagem permite trabalhar com problemas reais e bem fundamentados, além de aproximar os alunos da literatura da área. Dê preferência a artigos publicados de 2020 em diante.

Caso não encontre opções adequadas nas fontes listadas e identifique um dataset em outra venue, certifique-se de que possui alto fator de impacto ou classificação Qualis A1-A3 e consulte o professor previamente para aprovação.

Caso o grupo escolha um dataset de artigo científico, deve usar os dados originais do trabalho como base e propor perguntas de pesquisa, hipóteses e análises próprias. O objetivo não é replicar o artigo, mas desenvolver uma investigação nova e bem justificada a partir do mesmo material.

1.2 Requisitos mínimos do dataset

O dataset selecionado deve atender aos seguintes critérios técnicos para garantir a viabilidade e complexidade adequada do projeto:

Tabela 3: Requisitos do dataset final

Critério	Especificação
Registros	Mínimo de 10.000
Preditores	Mínimo de 15 (após integração e feature engineering)
Tipos de variáveis	Combinação de variáveis numéricas e categóricas
Integração	Possibilidade de integração com fontes adicionais
Potencial analítico	Adequado para análise preditiva (classificação ou regressão)

1.3 Formulação do Problema

Você deve desenvolver os seguintes elementos sobre seu dataset e a análise pretendida:

Perguntas de Pesquisa (1-2 perguntas específicas)

As perguntas devem ser específicas e mensuráveis, orientadas por dados e analiticamente interessantes.

Exemplos:

- *Como características socioeconômicas de um município brasileiro influenciam seu IDH?*
- *É possível prever o nível de desenvolvimento municipal baseado em indicadores disponíveis?*
- *Quais fatores têm maior peso na classificação de municípios como de alta qualidade de vida?*

Suas perguntas devem ser investigáveis através dos dados disponíveis, ter relevância prática e permitir análises que ajudem na tomada de decisão.

Contexto e justificativa (0,5-1 página)

Após definir suas perguntas, desenvolva uma fundamentação sólida que responda:

- Por que este problema é relevante?
- Qual o impacto prático da análise proposta?
- Quem se beneficiaria dos resultados obtidos?
- Como sua abordagem se diferencia de análises ou estudos já existentes sobre o tema?

1.4 Hipóteses Testáveis

Desenvolva 2-3 hipóteses que possam ser testadas com o dataset escolhido, **priorizando aquelas relacionadas à modelagem preditiva** (classificação ou regressão).

Exemplos de hipóteses:

- *H1: Municípios com maior investimento em educação per capita apresentam IDH superior*
- *H2: A renda média é o preditor mais forte do IDH municipal*
- *H3: Modelos ensemble superam modelos lineares na predição de desenvolvimento municipal*

1.5 Entregável da Etapa 1

Tabela 4: Documento PDF (1-2 páginas)

Item
Identificação do grupo e link do repositório Git para acompanhamento
Descrição do dataset escolhido (fonte, estrutura, tamanho estimado)
Contexto e justificativa do problema
1-2 perguntas de pesquisa bem formuladas
2-3 hipóteses testáveis

Tabela 5: Critérios de avaliação da etapa 1

Critério
Relevância e originalidade do problema
Clareza e especificidade das perguntas
Viabilidade das hipóteses para modelagem preditiva
Qualidade da escrita e estruturação

2 Integração e Limpeza de Dados

Integrar dados de múltiplas fontes e preparar um dataset limpo para análise, resolvendo problemas de qualidade comuns em projetos reais.

2.1 Enriquecimento com Fontes Externa

Esta etapa consiste em identificar e integrar pelo menos uma fonte externa de dados que contribua de forma relevante para o problema proposto. O objetivo é enriquecer o dataset principal com novas variáveis, melhorar o poder explicativo e preditivo da análise e aproximar o projeto de cenários reais de ciência de dados.

Esse enriquecimento deve ser planejado de forma justificada, mostrando por que a fonte adicional é útil para responder às perguntas de pesquisa e para apoiar a modelagem. O requisito de origem apresentado na Etapa 1 vale para o **dataset principal**; nesta etapa, o grupo deve integrar pelo menos uma fonte complementar externa.

Por exemplo, ao classificar casos de dengue com base apenas em contagens históricas, a incorporação de dados meteorológicos (chuva, temperatura) pode revelar padrões sazonais cruciais para a predição.

Estratégias de integração recomendadas:

- **Matching por identificadores únicos:** por exemplo, CPF, CNPJ, códigos municipais IBGE
- **Integração temporal:** séries históricas, dados mensais/anuais compatíveis
- **Matching geográfico:** coordenadas, CEP, códigos de região
- **Atributos categóricos:** setores econômicos, faixas etárias, classificações padronizadas

Fontes típicas para enriquecimento:

- Dados demográficos e socioeconômicos (IBGE, censos)
- Indicadores econômicos e financeiros (Banco Central, IPEADATA)
- Informações climáticas e ambientais (INMET, INPE)
- APIs públicas de contexto (geolocalização, eventos, mercado)

Quando utilizar múltiplas fontes, siga estas etapas:

1. Padronizar nomenclaturas e tipos de dados entre fontes
2. Resolver conflitos quando fontes divergem para o mesmo registro
3. Detectar e tratar registros duplicados
4. Criar identificadores únicos consistentes

2.2 Limpeza de Dados

Implemente soluções para os principais problemas de qualidade:

- **Missing values:** escolher estratégias de imputação adequadas
- **Outliers:** detectar valores extremos e decidir sobre tratamento
- **Inconsistências:** verificar dependências entre variáveis (dependências funcionais, se existirem) e corrigir possíveis erros
- **Padronização:** uniformizar formatos de datas, textos e códigos

Documente todas as transformações aplicadas e mantenha registro das decisões tomadas durante o processo de limpeza.

2.3 Entregável da etapa 2

Notebook Documentado Contendo

Item
Scripts/processo de integração com pelo menos uma fonte externa
Pipeline de limpeza reprodutível
Dataset final limpo

Tabela 6: Critérios de Avaliação da Etapa 2

Critério
Qualidade da integração com fontes externas e da limpeza
Documentação e reprodutibilidade

3 Análise Exploratória e Consultas SQL

3.1 Objetivo

Compreender os dados através de análises estatísticas e consultas SQL que respondam às perguntas de pesquisa, garantindo que os dados estejam em formato adequado para análise.

3.2 Preparação dos Dados em Formato Tidy

3.2.1 Organização dos Dados

Transformar o dataset limpo para formato **tidy data** seguindo os princípios fundamentais: cada variável forma uma coluna, cada observação forma uma linha e cada tipo de unidade observacional forma uma tabela.

3.2.2 Reestruturação Necessária

- **Transformações estruturais:** converter dados wide em long format quando necessário
- **Normalização:** separar variáveis compostas em colunas distintas
- **Padronização de tipos:** garantir tipos de dados apropriados
- Exportar dados preparados em formato **Parquet**

3.3 Consultas SQL Analíticas

Desenvolver consultas que revelem insights interessantes a partir dos dados em formato tidy, explorando:

- **Agregações complexas:** análises por grupos e períodos (ou equivalentes)
- **Análises temporais:** funções de janela para tendências e rankings
- **Consultas hierárquicas:** CTEs para análises em múltiplos níveis

Exemplos de tipos de consultas:

1. Tendências temporais e sazonalidade
2. Comparações entre grupos e categorias
3. Análises de concentração e distribuição
4. Detecção de padrões e anomalias
5. Correlações e dependências entre variáveis

3.4 Análise Exploratória e Teste de Hipóteses

Compreender a estrutura dos dados através de análises estatísticas progressivas e verificação preliminar das hipóteses de pesquisa, incluindo:

- **Análise univariada:** distribuições, medidas de tendência central e dispersão, identificação de padrões e valores atípicos
- **Análise bivariada:** correlações entre variáveis, visualizações de relacionamentos, comparações entre grupos
- **Análise multivariada:** matriz de correlações, análises de agrupamento, técnicas de redução dimensional
- **Teste de hipóteses:** formulação e verificação preliminar das hipóteses através de testes estatísticos apropriados e validação visual

Todas as análises devem ser acompanhadas de visualizações e interpretações que conectem os achados às perguntas de pesquisa.

3.5 Entregável da Etapa 3

Notebook e demais recursos:

Item
Pipeline de transformação para formato tidy
Produção e exportação do dataset final em formato Parquet
5+ consultas SQL documentadas com interpretações
Análises univariadas e bivariadas
Análises multivariadas
Visualizações interpretadas
Testes de hipóteses
Insights que orientem a etapa de modelagem

Tabela 7: Critérios de Avaliação da Etapa 3

Critério
Preparação tidy e geração do Parquet
Consultas SQL analíticas e insights
Qualidade das análises e visualizações
Conexão com perguntas de pesquisa

4 Modelagem com Machine Learning

4.1 Objetivo

Desenvolver modelos preditivos robustos que respondam às perguntas de pesquisa, demonstrando evolução e melhoria ao longo do processo.

4.2 Implementação de Modelos

4.2.1 Diversidade de Algoritmos (3+ obrigatórios)

Implementar modelos com diferentes níveis de complexidade para comparação:

- **Modelo simples:** Regressão Linear ou Logística (baseline interpretável)
- **Modelos mais complexos:** Random Forest, Redes Neurais, SVM ou outros algoritmos adequados ao problema

4.2.2 Feature Engineering

Aplicar transformações necessárias nos dados:

- **Transformações básicas:** encodings categóricos, normalização, tratamento de outliers
- **Criação de features:** gerar variáveis derivadas relevantes para o problema
- **Seleção de features:** identificar variáveis mais importantes para performance e interpretabilidade

4.3 Processo de Melhoria Iterativa

4.3.1 Desenvolvimento Incremental

- **Modelo baseline:** implementação inicial simples para estabelecer referência
- **Iterações sequenciais:** melhorias incrementais documentadas
- **Registro de experimentos:** o que funcionou, o que não funcionou e por quê

4.3.2 Otimização de Hiperparâmetros

- Tuning sistemático dos principais parâmetros
- Validação cruzada para generalização
- Comparação quantitativa antes e depois das otimizações

4.4 Avaliação e Interpretabilidade

4.4.1 Métricas de Performance

Utilizar métricas apropriadas ao tipo de problema (classificação, regressão) e ao contexto da análise, incluindo avaliação de erro e validação em dados não vistos.

4.4.2 Análise de Explicabilidade

- **Importância das features:** identificar variáveis mais influentes
- **Trade-off complexidade vs. interpretabilidade:** análise comparativa entre modelos
- **Interpretação contextual:** conectar resultados ao problema
- **Limitações identificadas:** reconhecer quando os modelos podem falhar

4.5 Entregável da Etapa 4

Notebook e demais recursos:

Item
Histórico de modelagem (baseline → final)
3+ algoritmos implementados e comparados
Processo de tuning com resultados antes e depois
Análise de interpretabilidade vs. performance
Recomendação do melhor modelo com justificativa
Validação robusta dos modelos finais

Tabela 8: Critérios de Avaliação da Etapa 4

Critério
Diversidade e adequação dos algoritmos
Documentação do processo
Qualidade do tuning e validação
Interpretação no contexto do problema

5 Relatório e Comunicação

Vocês devem comunicar de forma clara e profissional os resultados obtidos, demonstrando capacidade de traduzir análises técnicas em conclusões que podem gerar ações e apoiar a tomada de decisão.

5.1 Relatório Técnico (6-8 páginas sem contar referências)

Documento final que expande e consolida o relatório inicial, contendo:

- Resumo com principais descobertas
- Definição do problema e perguntas de pesquisa (expandido da Etapa 1)
- Metodologia completa e limitações
- Resultados das análises
- Discussão dos resultados
- Recomendações práticas

- Trabalhos futuros

Importante: O relatório deve ser escrito integralmente pelos alunos. O uso de IA é permitido apenas para correção do texto já produzido pelos estudantes.

5.2 Materiais de Apresentação

5.2.1 Apresentação Principal (16-21 minutos)

Apresentação com os integrantes. Deve ser clara, objetiva e bem distribuída entre os integrantes do grupo.

Estrutura da apresentação:

- **Contexto e problema** (2-3 min): motivação e perguntas de pesquisa
- **Demonstração dos dados** (3-4 min): dataset, integração e limpeza
- **Metodologia** (5-6 min): pipeline analítico e modelos implementados
- **Resultados principais** (4-5 min): descobertas e performance dos modelos
- **Lições aprendidas** (2-3 min): o que funcionou, o que não funcionou, próximos passos

5.3 Entregável da Etapa 5

Item
Relatório técnico em PDF
Slides da apresentação
Pipeline funcionando
Repositório Git organizado e documentado

Tabela 9: Critérios de Avaliação da Etapa 5

Critério
Clareza e qualidade da escrita
Estrutura e fluidez da apresentação
Demonstração técnica efetiva
Reflexão crítica (lições aprendidas)